

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Ciencias de la Computación

CC3084 – Data Science · Semestre II 2026



Laboratorio 2 — Deep Learning

Modelos LSTM y exploración de series con catch22

Ingreso de viajeros internacionales a Guatemala (2009–2026)

Integrantes

Nicolás Concua (23197)

Felipe Aguilar (23195)

Guatemala, 2 de agosto de 2026

1. Introducción

Este informe extiende el análisis de series de tiempo del ingreso de viajeros internacionales a Guatemala (enero 2009 – junio 2026) con técnicas de aprendizaje profundo. Se persiguen dos objetivos: (a) construir modelos LSTM para pronosticar dos series y compararlos con los mejores modelos clásicos del Laboratorio 1; y (b) caracterizar la similitud entre las siete series construidas mediante el algoritmo catch22. Se trabajó con las mismas definiciones de series y la misma partición 70/30 del laboratorio anterior, de modo que las comparaciones sean directas y justas.

Las siete series analizadas son: la serie Total (Turista + Excursionista), las vías de ingreso Aérea, Terrestre y Marítima (crucevistas), y los tres países de mayor volumen: El Salvador, Estados Unidos y Honduras. El conjunto de entrenamiento cubre ene-2009 a mar-2021 (147 meses) y el de prueba abr-2021 a jun-2026 (63 meses), un horizonte dominado por la recuperación pospandemia.

2. Ejercicio 1 — Modelos LSTM

2.1 Metodología y tuneo

Se modelaron las series Total y Aérea. Para una comparación limpia con los modelos ARIMA del Lab 1 (que usan una diferencia regular, $d = 1$) y para estabilizar el pronóstico recursivo, las LSTM aprenden las log-diferencias de cada serie (objetivo estacionario). Por serie se evaluaron seis configuraciones distintas — variando la ventana (look_back de 12 o 24 meses), el número de unidades, el número de capas y el dropout— con early stopping sobre una validación interna. El mejor modelo se seleccionó por la pérdida de validación (sin usar el conjunto de prueba). El pronóstico de los 63 meses es recursivo y no utiliza ningún valor real del test, igual que el forecast del ARIMA.

2.2 Mejor modelo y predicción (incisos 1.3–1.4)

Serie	Mejor config.	RMSE	MAE	MAPE
Total	C1 (lb 12, 32u, 1 capa)	163,375	148,944	56.8 %
Aérea	C2 (lb 12, 64u, 1 capa)	40,137	34,792	34.4 %

En ambas series las configuraciones ganadoras son pequeñas (ventana de un año, una sola capa): con solo 147 meses de entrenamiento, los modelos más grandes sobreajustan y su error se acumula más rápido en el pronóstico recursivo. En términos relativos, la vía Aérea (MAPE 34.4 %) es más predecible que la serie Total (MAPE 56.8 %).




Figura 1. Pronóstico del mejor LSTM (línea roja) frente al test real, series Total y Aérea.

2.3 Comparación con el Laboratorio 1

Sobre el mismo test y con las mismas métricas se comparó cada mejor LSTM contra el mejor modelo del Lab 1 (ARIMA(1,1,1) no estacional en ambas series). El criterio principal fue el RMSE fuera de muestra.

Serie	RMSE Lab 1 (ARIMA)	RMSE LSTM	Δ RMSE	Ganador
Total	169,120	163,375	-3.4 %	LSTM
Aérea	38,375	40,137	+4.6 %	ARIMA (Lab 1)

El resultado es mixto y muy ajustado: cada enfoque gana una serie y las diferencias son menores al 5 %. Para estas series univariadas, cortas y con un cambio de régimen (la pandemia) justo en la frontera train/test, la LSTM afinada es competitiva con el ARIMA pero no lo supera de forma clara —un hallazgo coherente con la literatura de comparación ARIMA vs. LSTM—. Ambos modelos subestiman la fuerza de la recuperación, precisamente por el quiebre estructural al inicio del horizonte de prueba.

3. Ejercicio 2 — Exploración con catch22

3.1 Idea y matriz de características (incisos 2.1–2.4)

catch22 (CAnonical Time-series CHaracteristics) resume una serie en 22 características seleccionadas de la biblioteca hctsa por ser poco redundantes, rápidas de calcular y con buen poder discriminante. Describen distribución, autocorrelación, periodicidad, entropía/predictibilidad, cambios de régimen y escalamiento. Convierte series de distinta escala y longitud en vectores comparables. Cada serie se z-normalizó antes de extraer catch22 (para centrarse en la forma y no en la magnitud) y se construyó la matriz 7×22 (7 series × 22 características); luego cada característica se estandarizó entre las siete series antes de PCA, clustering y distancias.

3.2 Análisis (inciso 2.5)

Los dos primeros componentes principales explican el 66.4 % de la variación (PC1 = 44.5 %, PC2 = 21.8 %; el tercero suma 19.3 %). La Figura 2 proyecta las series en ese plano, la Figura 3 muestra el clustering jerárquico (Ward) y la Figura 4 el mapa de distancias euclidianas.




Figura 2. PCA de las series en el espacio catch22, coloreadas por categoría.




Figura 3. Clustering jerárquico (enlace Ward) de las siete series.




Figura 4. Mapa de distancias euclidianas entre series en el espacio catch22.

3.3 Interpretación (incisos 2.6–2.11)

- Series más similares (2.7): el par más cercano es Total–Terrestre (distancia 3.34), seguido de Terrestre–El Salvador (4.78) y El Salvador–Estados Unidos (4.91). Coherente con que la vía Terrestre domina el volumen total, pero al estar z-normalizadas revela que comparten dinámica, no solo magnitud.
- Características más discriminantes (2.8): en PC1 pesan el error de predicción local (FC_LocalSimple_mean3_stderr), la información mutua (CO_HistogramAMI_even_2_5), el centroide espectral (SP_Summaries_welch_rect_centroid) y los motivos simbólicos; en PC2, la asimetría temporal (CO_trev_1_num), las escalas de autocorrelación y la periodicidad. La separación mezcla predictibilidad, contenido espectral, dependencia temporal, periodicidad y asimetría.
- Grupos naturales (2.9): cortando el árbol en tres se obtienen {Total, Terrestre, El Salvador, Estados Unidos}, {Aérea, Honduras} y {Marítima} sola. El primer grupo comparte persistencia, choque pandémico y recuperación.
- Categorías (2.10): no se agrupan de forma estricta. Las tres vías caen en ramas distintas y los países no forman un solo bloque (El Salvador y EE.UU. cercanos, Honduras aparte). El tipo administrativo de la serie no determina por sí solo su dinámica.
- Serie más atípica (2.11): Marítima, con la mayor distancia promedio (8.87) y el extremo de PC1 (6.62). Su patrón de cruceros —intermitente, 45 meses en cero, temporada extrema y cobertura más corta (hasta 2022)— explica su aislamiento; parte de la diferencia se debe a su ventana temporal distinta.

3.4 Comparación con el EDA y descubrimientos (incisos 2.12–2.13)

Los agrupamientos de catch22 son consistentes con el análisis exploratorio del Lab 1: la tendencia, el choque pandémico, la recuperación y la ACF persistente se reflejan en la cercanía Total–Terrestre y en el aislamiento

de Marítima (que el EDA ya señalaba como intermitente y muy estacional). catch22 agrega matices: Aérea y Estados Unidos tenían las mayores fuerzas estacionales en el Lab 1, pero catch22 no las agrupa, porque pondera 22 propiedades simultáneas y no solo la estacionalidad. Tres descubrimientos que el EDA tradicional no evidenciaba:

- La similitud cruza categorías: conviene segmentar modelos por dinámica observada y no por el tipo administrativo (vía o país).
- Compartir estacionalidad fuerte no implica compartir el perfil completo (Aérea vs. Estados Unidos).
- Existe redundancia empírica incluso en una selección poco redundante (correlación ≈ 0.996 entre dos características en estas siete series), que PCA condensa; y la rareza de Marítima es multidimensional, no solo por sus ceros.

4. Inciso 2.14 — LSTM con características de catch22

Para la serie Aérea se construyó un LSTM que incorpora las 22 características de catch22 calculadas sobre ventanas deslizantes (distintas de la matriz por serie completa del punto anterior). Para aislar su efecto se entrenó, con la misma arquitectura y representación (nivel en log escalado), un LSTM sin y otro con dicho contexto, y se compararon con el mejor LSTM del Ejercicio 1 (C2, en log-diferencias).

Modelo	RMSE	MAE	MAPE	Δ RMSE vs Ex1
LSTM Ex1 (C2, log-dif)	40,137	34,792	34.4 %	—
LSTM puro (nivel)	88,571	85,357	89.7 %	+120.7 %
LSTM + catch22 (nivel)	41,159	35,951	35.1 %	+2.6 %




Figura 5. Aérea: el LSTM puro (verde) colapsa; con catch22 (rojo) el pronóstico se acerca al real.

Añadir las características de catch22 reduce el RMSE casi a la mitad frente al LSTM puro en la misma representación (de 88,571 a 41,159) y deja al modelo prácticamente a la par del mejor LSTM del Ejercicio 1 (diferencia de 2.6 %). Es decir, catch22 aporta a la red una síntesis de la dinámica reciente (autocorrelación, periodicidad, predictibilidad) que recupera por completo la brecha de una representación que sin ellas era claramente inferior. El aporte tiene alta varianza entre configuraciones y el contexto se congela durante la recursión para no desestabilizarla; la conclusión no es que la LSTM con catch22 gane, sino que las características son una fuente de información valiosa.

5. Conclusiones

- Los modelos LSTM son competitivos con los modelos clásicos del Lab 1: cada enfoque gana una serie (LSTM en Total, ARIMA en Aérea) con diferencias menores al 5 %. Ninguno domina en este horizonte con quiebre pandémico.
- catch22 confirma cuantitativamente la singularidad de Marítima y la cercanía Total–Terrestre, y revela que las categorías administrativas (vías, países) no forman grupos naturales completos.
- Las características de catch22 tienen valor predictivo: igualan al mejor LSTM del Ejercicio 1 partiendo de una representación más débil, aunque no lo superan.
- Con solo siete series y un cambio de régimen en 2020, los agrupamientos deben tomarse como hipótesis de trabajo (para segmentar o elegir comparables), no como clases definitivas.